PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Projeto: Acidentes em rodovias federais brasileiras em 2025
Curso e turma: CBSI - 6A - N - 2026/2
Professor ou professora: Marina de Lara
Equipe: Giovanna Rita Santos Daniel, João Lucas do Prado Ribeiro, Leonardo Stall e Mirella Haisi Szvarça
Repositório: https://github.com/mirellahaisi/Acidentes_2025
Entrega: Curitiba, outubro/2026

Este documento acompanha a implementação no repositório. Registre o caminho dos arquivos, notebooks ou células que comprovam cada etapa. O resultado do RA1 será a base para os próximos RAs.

RA1 / 01

Problema e perguntas analíticas

Contexto e problema

Os acidentes de trânsito em rodovias federais impactam diversos usuários das rodovias e mobilizam serviços de fiscalização, atendimento e infraestrutura. O projeto tem o objetivo de investigar como as ocorrências registradas pela PRF e sua gravidade se distribuem entre localidades, períodos e condições registradas.

Objetivo e recorte

Preparar um conjunto de dados de acidentes registrados pela PRF em rodovias federais brasileiras durante o ano de 2025, por meio de ingestão reproduzível, avaliação da qualidade e tratamento justificado das inconsistências identificadas. A unidade de análise das perguntas propostas será a ocorrência de acidente. Como a fonte selecionada apresenta dados agrupados por pessoa, será necessário distinguir os registros de envolvidos dos identificadores das ocorrências, evitando contar o mesmo acidente mais de uma vez nas análises posteriores.

Perguntas analíticas

ID	Pergunta a investigar	Dados necessários
P1	Como a quantidade de acidentes varia entre UFs e rodovias federais no período selecionado?	[id, uf, br]
P2	Como as ocorrências se distribuem entre meses, dias da semana e horários?	[data_inversa, dia_semana, horário]
P3	Como a proporção de acidentes com vítimas fatais varia entre os tipos de acidente?	[tipo_acidente, mortos]
P4	Como a gravidade dos acidentes registrados varia entre condições meteorológicas e fases do dia?	[condicao_metereologica, fase_dia, mortos, feridos_leves, feridos_graves]
P5	Como a participação de condutores menores de idade nos acidentes varia entre tipos de veículo e UFs?	[id, tipo_envolvido, idade, tipo_veiculo, uf

Viabilidade inicial

A fonte selecionada será avaliada quanto a disponibilidade e a qualidade das informações de localização, data, horário, características dos acidentes e consequências para os envolvidos. Esses dados permitirão investigar as perguntas propostas, desde que os registros de pessoas sejam corretamente associados as respectivas ocorrências. As principais limitações são a cobertura restrita aos acidentes registrados pela PRF e a ausência, de informações sobre o volume de tráfego necessário para estimar o risco por viagem.

RA1 / 02

Fontes de dados e ingestão

Ficha da fonte

Identificação: Acidentes de trânsito da PRF, agrupados por pessoa, 2025
Origem e acesso: Polícia Rodoviária Federal. endereço oficial e link do arquivo. Acesso em: 09/10/2026
Formato e volume: Arquivo CSV, com separador ponto e vírgula (;), codificação ISO-8859-1, 584.010 registros e 37 atributos originais.
Cobertura: 01/01/2025 até 31/12/2025. ocorrências registradas pela PRF em rodovias federais brasileiras
Condições de uso: Dados abertos

Relação com o problema

A fonte poderá apoiar as quatro perguntas analíticas do projeto. As informações de localização serão utilizadas para investigar a distribuição das ocorrências entre UFs e rodovias. Os atributos temporais permitirão analisar sua distribuição ao longo de 2025, e as informações sobre o acidente e os envolvidos apoiarão o estudo de sua gravidade.

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	Obtenção do arquivo CSV de acidentes de 2025 e disponibilização do arquivo no ambiente de execução.	acidentes2025_todas_causas_tipos.csv
2	Leitura do CSV com PySpark, separador `;` e codificação ISO-8859-1.	Notebook: seção 2.1
3	Conferência da quantidade de registros, dos atributos, dos tipos e das datas, seguida da exploração da qualidade dos dados.	Notebook: seções 3.1 a 3.12

Resultado da ingestão

A leitura da base original resultou em **584.010** registros e 37 atributos. O arquivo foi carregado no ambiente do Google Colab por meio do PySpark, mantendo o conjunto original em **df_original** para as verificações de qualidade. A base original foi preservada durante o processo, e as mudanças são aplicadas a um DataFrame separado, chamado de **df_tratado**.

RA1 / 03

Compreensão e qualidade

Unidade de observação: Na base original, cada linha representa um registro ligado a uma pessoa envolvida em um acidente, sendo possível ter mais de uma linha para o mesmo acidente. O identificador *id* permite associar registros à mesma ocorrência, enquanto *pesid* identifica uma pessoa. Assim, a quantidade de linhas da base original não equivale à quantidade de acidentes distintos.

Identificação dos registros: O campo *id* identifica o acidente, e *pesid* identifica a pessoa. A base original apresenta **72.529 identificadores distintos de acidente** e **65.382 identificadores associados a mais de uma linha**. Essas repetições não foram consideradas automaticamente duplicidades, pois podem representar diferentes pessoas ou tipos registrados na mesma ocorrência. O notebook também investiga combinações de identificadores e atributos para distinguir repetições legítimas de possíveis duplicações.

Dicionário inicial dos dados

Atributo	Significado	Tipo e formato	Unidade ou domínio
id	Identificador do acidente	Texto (string)	Identificador da ocorrência
pesid	Identificador da pessoa envolvida	Texto (string)	Pode estar ausente
data_inversa	Data do acidente	Data após a preparação	Datas do período de 2025
dia_semana	Dia da semana do acidente	Texto (string)	Categorias de dias da semana
horario	Horário do acidente	Texto validado no formato HH:mm:ss	Horário do dia
uf	Unidade federativa	Texto (string)	Siglas dos estados
br	Número da rodovia federal	Inteiro (integer)	Número da BR
tipo_acidente	Tipo de acidente registrado	Texto (string)	Categorias da fonte
classificacao_acidente	Classificação do acidente	Texto (string)	Categorias da fonte; pode estar ausente
condicao_metereologica	Condição meteorológica registrada	Texto (string)	Categorias da fonte
fase_dia	Fase do dia	Texto (string)	Categorias da fonte
tipo_envolvido	Tipo de envolvimento da pessoa	Texto (string)	Ex.: condutor, passageiro, pedestre
idade	Idade registrada para a pessoa	Inteiro (integer) após a preparação	Valores plausíveis; ausências preservadas

Atributo	Significado	Tipo e formato	Unidade ou domínio
tipo_veiculo	Tipo de veículo associado ao registro	Texto (`string`)	Categorias da fonte; pode não se aplicar
mortos	Indicador individual de morte	Inteiro (`integer`)	Indicador 0/1

Diagnóstico de qualidade

Considere ausências, duplicidades, tipos, formatos, valores inválidos, categorias e possíveis outliers. Registre também verificações sem problemas; use "não se aplica" com justificativa quando necessário.

ID	Verificação e regra	Resultado observado	Evidência
Q1	Valores ausentes e marcadores textuais	Foram identificadas diferentes representações de ausência, incluindo NA, campos vazios e marcadores textuais. A idade apresenta 106.045 ausências após o tratamento; `pesid` apresenta 56.801.	Notebook, seções 3.2 e 4.6.
Q2	Linhas idênticas e repetição de identificadores	Há 72.529 IDs distintos de acidente, dos quais 65.382 aparecem em mais de uma linha. A repetição de `id` não é, por si só, duplicação indevida.	Notebook, seções 3.1 e 3.6.1.
Q3	Conversão de datas, horários e números	Na auditoria de conversões, não foram identificadas falhas numéricas remanescentes antes da tipagem final. A saída também registra zero datas e zero horários inválidos nessa verificação.	Notebook, seção 4.5.
Q4	Datas fora de 2025	O projeto considera os registros de 2025. A contagem específica de datas fora do período deve ser confirmada na saída correspondente antes de registrar um número.	Notebook, seção 3.5, e filtro temporal do projeto.
Q5	Categorias inconsistentes	O notebook explora as categorias existentes e os marcadores de ausência. Não há, no material consultado, um resultado numérico consolidado que comprove a quantidade de categorias inconsistentes.	Notebook, seções 3.3 e 4.2.
Q6	Valores incompatíveis com o significado dos campos	Foram encontrados 432 registros com idade superior a 110 anos e 29.808 registros com ano de fabricação igual a zero. A idade igual a zero aparece em 603 registros e foi mantida.	Notebook, seções 3.8, 3.9 e 4.3.

Impacto dos problemas identificados

Os problemas de qualidade podem comprometer a interpretação dos resultados se não forem tratados adequadamente. A repetição de identificadores é muito importante, pois contar linhas como acidentes distintos pode superestimar a quantidade de ocorrências. Os marcadores de ausência e os valores inválidos podem prejudicar cálculos e comparações, principalmente nas variáveis de idade, classificação do acidente e informações sobre veículos. Além disso, a ausência de identificação da pessoa limita análises individuais, como a investigação de condutores menores de idade. Por isso, as decisões de preparação preservam os registros sempre que possível, distinguem informações desconhecidas de campos não aplicáveis e evitam preencher valores por suposição.

RA1 / 04

Limpeza e preparação

Registro das decisões

Decisão e diagnóstico D1 - Diferenciação entre informações ausentes e campos não aplicáveis, relacionada ao diagnóstico Q1.

Problema e abrangência

Nos registros de Pedestre, Cavaleiro e Testemunha, a ausência de informações em *id_veiculo*, *tipo_veiculo*, *marca* e *ano_fabricacao_veiculo* pode representar a não aplicabilidade desses atributos. Contabilizar todas essas ausências como falta de informação prejudicaria a avaliação da qualidade dos dados.

Tratamento e justificativa

Foram criados quatro indicadores booleanos, com o sufixo *_nao_se_aplica*, um para cada atributo de veículo. Cada indicador recebe verdadeiro somente quando o campo está ausente e o tipo de envolvimento corresponde a Pedestre, Cavaleiro ou Testemunha.

Essa regra preserva os valores preenchidos e mantém todos os registros. Os indicadores permitem distinguir a não aplicabilidade do desconhecimento e excluir os casos não aplicáveis do cálculo dos percentuais de falta de informação.

Implementação Seção: 4.1

Validação após o tratamento

Na seção 4.1, o código verifica se existe algum campo preenchido marcado como não aplicável, interrompendo a execução caso encontre essa inconsistência. Também apresenta a quantidade de marcações por atributo e exemplos dos registros classificados.

Na seção 4.6, são verificadas a tipagem booleana dos indicadores, a inexistência de valores nulos nesses indicadores e a ausência de marcações de não aplicabilidade em campos preenchidos. A etapa também confere a preservação da quantidade de linhas e das colunas originais, com o acréscimo dos quatro indicadores.

Decisão e diagnóstico D2 - Padronização dos valores ausentes e manutenção das informações desconhecidas, relacionada ao diagnóstico Q1.

Problema e abrangência

As ausências podem estar representadas por valores nulos, campos vazios ou marcadores textuais, como NA, N/A, Ignorado e Não Informado. Essas diferentes representações dificultam a contagem das informações ausentes e a conversão dos tipos. O tratamento abrange as 37 colunas originais.

Tratamento e justificativa

Os marcadores reconhecidos pela função campo_ausente() foram padronizados para o valor NULL nativo do Spark. A identificação desconsidera diferenças entre letras maiúsculas e minúsculas e espaços nas extremidades. Nos demais valores, foram removidos apenas os espaços nas extremidades, preservando o conteúdo informativo.

Não foram estimados valores para preencher informações desconhecidas, como identificador da pessoa, idade e tipo de envolvimento. Essa decisão evita introduzir informações sem evidência. A distinção entre ausência e não aplicabilidade foi preservada pelos indicadores criados em D1, mantendo todas as linhas e o DataFrame original.

Implementação seção 4.2

Validação após o tratamento

A seção 4.2 apresenta, por coluna, a quantidade de ausências reconhecidas antes da normalização e exemplos de registros com pesid nulo após o tratamento. Essa contagem inclui tanto marcadores textuais quanto valores que já eram nulos, não representando exclusivamente novas conversões.

Na seção 4.6, o código apresenta as quantidades finais de nulos, distinguindo casos não aplicáveis de ausências em registros aplicáveis. Também verifica a preservação da quantidade de linhas e das colunas originais. Os valores dessa conferência refletem o conjunto dos tratamentos realizados, incluindo as regras de invalidez e as conversões posteriores.

Decisão e diagnóstico D3 - Tratamento de valores inválidos de idade e ano de fabricação, relacionado ao diagnóstico Q6.

Problema e abrangência

A decisão abrange as colunas idade e ano_fabricacao_veiculo. Foram estabelecidas regras para tratar idades negativas ou superiores a 110 anos e anos de fabricação iguais a zero ou negativos. Esses valores podem comprometer as análises sobre o perfil dos envolvidos e as características dos veículos.

Tratamento e justificativa

Na coluna idade, valores negativos ou superiores a 110 foram substituídos por NULL. O limite superior corresponde à regra de plausibilidade adotada pelo projeto. A idade igual a zero foi preservada, pois pode representar uma criança com menos de um ano.

Na coluna ano_fabricacao_veiculo, valores iguais a zero ou negativos também foram substituídos por NULL, por não representarem anos de fabricação válidos no contexto da base.

Como os valores corretos são desconhecidos, não foram realizadas correções por estimativa. Apenas os campos afetados foram alterados, mantendo as linhas e preservando os dados originais em df_original. Valores estatisticamente extremos não foram excluídos automaticamente: o tratamento seguiu as regras explícitas, sem utilizar o intervalo interquartil como critério de exclusão.

Implementação seção 4.3

Validação após o tratamento

A seção 4.3 contabiliza os valores que atendem à regra de invalidez de cada coluna, apresenta exemplos antes da alteração e informa a quantidade total de valores nulos após a substituição. Esse total inclui as ausências que já existiam, portanto não equivale exclusivamente à quantidade de valores invalidados nessa etapa.

A seção 4.6 complementa a conferência ao verificar a preservação da quantidade de linhas e os tipos inteiros de idade e ano_fabricacao_veiculo após a conversão.

Decisão e diagnóstico D4 - Adequação dos tipos e formatos dos dados, relacionada ao diagnóstico Q3.

Problema e abrangência

Na ingestão, todas as colunas foram lidas como texto para preservar os valores da fonte. Entretanto, análises numéricas e temporais exigem tipos apropriados. A conversão precisa considerar números com vírgula decimal e identificar conteúdos incompatíveis, evitando perdas de informação não registradas.

Tratamento e justificativa

Após a normalização das ausências e o tratamento dos valores inválidos, foram realizadas as seguintes adequações:

- Conversão para inteiro de idade, ano_fabricacao_veiculo, br, ordem_tipo_acidente, ilesos, feridos_leves, feridos_graves e mortos.
- Conversão para double, permitindo casas decimais, de km, latitude e longitude, substituindo a vírgula decimal por ponto antes da conversão.
- Conversão de data_inversa para o tipo data.
- Validação de horario, mantendo-o como texto no formato HH:mm:ss. Horários válidos informados apenas com horas e minutos recebem segundos iguais a 00.
- Preservação de id, pesid e id_veiculo como texto, pois representam identificadores.

Valores incompatíveis com os tipos esperados são contabilizados e convertidos para NULL. Nos campos inteiros, valores fracionários ou fora do intervalo suportado também são considerados incompatíveis. Essa verificação evita truncamentos indevidos e permite acompanhar os efeitos das conversões.

Implementação seção 4.5

Validação após o tratamento

A seção 4.5 apresenta a quantidade de valores numéricos incompatíveis por coluna e as contagens de datas e horários inválidos. Após o tratamento das incompatibilidades numéricas, compara a quantidade de valores não nulos antes e depois de cada conversão, interrompendo a execução caso surjam novos nulos não contabilizados.

A seção 4.6 verifica se as colunas numéricas, a data e os identificadores possuem os tipos definidos. O esquema do DataFrame também é exibido para conferência.

Decisão e diagnóstico D5 - Preservação dos registros e respeito à unidade de observação, relacionada ao diagnóstico Q2.

Problema e abrangência

A base apresenta múltiplas linhas associadas ao mesmo acidente, pessoa ou veículo, em razão das diferentes pessoas, causas e tipos de acidente registrados. Portanto, a repetição de id, pesid ou id_veiculo não caracteriza, isoladamente, uma duplicação indevida. Excluir registros apenas pela repetição desses identificadores poderia eliminar informações relevantes.

Tratamento e justificativa

Todas as linhas foram mantidas no DataFrame df_tratado, sem exclusão automática por repetição de identificadores. Os registros com identificadores ausentes também foram preservados, pois podem conter outras informações úteis sobre as ocorrências.

A decisão considera que uma linha da base não equivale necessariamente a um acidente ou a uma pessoa distinta. As repetições foram investigadas por meio das frequências dos identificadores, da diversidade dos atributos associados e da verificação de uma chave composta. Assim, a limpeza preserva o detalhamento da fonte, enquanto as contagens analíticas posteriores devem utilizar identificadores e agrupamentos compatíveis com a unidade estudada.

Implementação seções 3.6, 3.6.1, 3.6.1.1 e 3.6.2

Validação após o tratamento

As verificações exploratórias apresentam a frequência dos identificadores, exemplos dos registros associados e a quantidade de combinações repetidas da chave composta por id, pesid, id_veiculo, causa_acidente e ordem_tipo_acidente. Esses resultados permitem examinar as repetições sem classificá-las automaticamente como erros.

Na seção 4.6, o código compara a quantidade de linhas de df_tratado com a de df_original, interrompendo a execução caso exista diferença. Também verifica a manutenção das colunas originais, com o acréscimo dos quatro indicadores de não aplicabilidade.

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência
D1	Diferenciar campos de veículo não aplicáveis de informações desconhecidas.	Acréscimo de quatro indicadores booleanos, sem apagar valores preenchidos nem excluir linhas.	Seções 4.1 e 4.6.
D2	Padronizar marcadores de ausência para NULL e remover espaços nas extremidades dos textos.	Tratamento das 37 colunas originais, preservando as ausências sem preenchimento por estimativa.	Seções 4.2 e 4.6.

Decisão	Ação executada	Impacto nos dados	Evidência
D3	Substituir por NULL idades negativas ou superiores a 110 e anos de fabricação iguais a zero ou negativos.	Alteração dos valores que atendem às regras em idade e ano_fabricacao_veiculo, mantendo as linhas e as idades iguais a zero.	Sessão 4.3.
D4	Adequar os tipos numéricos, converter datas e validar e padronizar horários, com auditoria das conversões.	Oito campos convertidos para inteiro, três para double e um para data; horário padronizado como texto e identificadores mantidos como texto.	Seções 4.5 e 4.6.
D5	Manter os registros, sem exclusão automática por repetição de identificadores.	Preservação de todas as linhas durante a limpeza, mantendo o detalhamento das pessoas, veículos, causas e tipos de acidente.	Seções 3.6 a 3.6.2 e 4.6.

RA1 / 05

Conjunto de dados resultante

Arquivo ou conjunto final: A base preparada para o RA1 é representada pelo DataFrame df_tratado, que mantém os 584.010 registros originais, as 37 colunas de origem com tipos corrigidos e quatro indicadores booleanos de não aplicabilidade de campos veiculares, totalizando 41 colunas. O notebook também cria df_transformado, com 45 colunas, e prevê sua exportação para Parquet no caminho /content/ra1_acidentes_2025_transformados_parquet.

Unidade de observação final: No conjunto df_tratado, cada linha continua representando um registro da base original associado a uma pessoa ou a informações incompletas de envolvimento. A limpeza preserva a quantidade de linhas e não realiza a consolidação por acidente. Para as próximas etapas, o notebook cria conjuntos auxiliares separados por acidente, acidente–tipo e pessoa, respeitando as chaves de cada análise.

Dicionário atualizado: O dicionário inicial dos atributos está documentado na seção 2.2 do notebook. Os tipos finais dos atributos e os quatro indicadores adicionais de não aplicabilidade são apresentados nas seções 4.5 e 4.6, com o esquema dos conjuntos resultantes na seção 6.

Comparação antes e depois

Medida	Após ingestão	Após preparação	Explicação da diferença
Registros	584.010	584.010	A limpeza preservou todas as linhas.
Atributos	37	41	Foram acrescentados quatro indicadores booleanos de não aplicabilidade de campos veiculares.
Idades inválidas acima de 110	432	0 valores mantidos como idade válida por essa regra	Os valores incompatíveis foram convertidos para NULL; as linhas foram preservadas.
Ano de fabricação igual a zero	29.808	0 valores mantidos como ano válido por essa regra	Os zeros foram convertidos para NULL; as linhas foram preservadas.

Verificações finais

O notebook verifica se a quantidade de registros foi preservada, se as 37 colunas originais permanecem na base preparada, se os tipos finais correspondem aos definidos para cada atributo e se os quatro indicadores de não aplicabilidade são consistentes. Também calcula os percentuais finais de ausência, considerando separadamente os campos não aplicáveis e os registros em que a informação deveria estar disponível. A exportação para Parquet possui verificações de quantidade de linhas e de compatibilidade do esquema após a recarga.

Limitações e pendências

A base apresenta ausências em atributos pessoais e de veículos, além de registros sem identificação da pessoa envolvida. Essas limitações restringem determinadas análises individuais e devem ser consideradas na

interpretação dos resultados. Os valores desconhecidos não são preenchidos por estimativa, e registros sem classificação do acidente são mantidos sem inferir automaticamente sua gravidade. A análise de condutores menores de idade dependerá da disponibilidade e da validade dos campos de tipo de envolvimento, idade e veículo. A execução completa e a disponibilidade permanente do arquivo final exportado devem ser confirmadas no repositório.

RA1 / 06

Organização e reprodutibilidade

Repositório mirellahaisi/Acidentes_2025
Branch: main
Versão consultada: commit 03a9fcf, com a mensagem “RA1 e RA2”

Ambiente

Python 3, executado no Google Colab, com Apache Spark por meio da biblioteca PySpark. O processamento utiliza recursos de Spark SQL e módulos da biblioteca padrão do Python. As versões específicas de Python e PySpark não estão registradas no notebook, e o repositório não contém arquivo de dependências.

Localização dos artefatos

Artefato	Caminho ou forma de obtenção
Dados brutos	Arquivo acidentes2025_todas_causas_tipos.csv, obtido no portal de dados abertos da PRF, referente a 2025 e agrupado por pessoa, com todas as causas e tipos. Deve ser disponibilizado em /content/acidentes2025_todas_causas_tipos.csv no Colab, ou em outro caminho definido pela variável de ambiente CAMINHO_DADOS. Não está incluído no repositório.
Código de ingestão e preparação	Notebook Projeto_Acidentes_2025_RA1_RA2-3.ipynb, localizado na raiz do repositório. A ingestão está na seção 2.1, a exploração na seção 3 e a limpeza e preparação na seção 4.
Dados preparados	O conjunto limpo é disponibilizado como df_tratado, após a seção 4.6. A seção 6 exporta o conjunto com as transformações adicionais, df_transformado, para o diretório /content/ra1_acidentes_2025_transformados_parquet, em formato Parquet. Esse diretório é gerado no ambiente de execução e não está incluído no repositório.
Documentação e dependências	Explicações metodológicas nas células de texto do próprio notebook e no documento RA1, mantido separadamente. Não há README.md nem requirements.txt no repositório consultado.

Passos para reprodução

Ordem	Instrução executável	Resultado esperado
1	Abrir o notebook Projeto_Acidentes_2025_RA1_RA2-3.ipynb no Google Colab e conectar um ambiente Python 3. Caso necessário, instalar PySpark com %pip install pyspark, conforme a orientação da seção 2.1.	Ambiente conectado e biblioteca PySpark disponível para importação.

Ordem	Instrução executável	Resultado esperado
2	Obter o CSV de acidentes de 2025 da PRF, agrupado por pessoa, com todas as causas e tipos, e carregá-lo no Colab em /content/acidentes2025_todas_causas_tipos.csv.	Arquivo disponível no caminho utilizado pela variável CAMINHO_DADOS.
3	Executar sequencialmente as células das seções 2 a 6 do notebook, abrangendo ingestão, exploração, limpeza, transformação e exportação. Manter EXPORTAR_PARQUET = True, conforme configurado no notebook.	Criação dos DataFrames df_original, df_tratado e df_transformado, seguida da gravação do conjunto transformado em Parquet.
4	Conferir as verificações da seção 4.6 e a gravação e releitura do Parquet na seção 6. Localizar o diretório /content/ra1_acidentes_2025_transformados_parquet.	Para a base utilizada no projeto: 584.010 linhas preservadas, 41 colunas em df_tratado e 45 em df_transformado. Exibição da mensagem “Arquivo Parquet produzido e validado”, após a conferência da quantidade de linhas e dos nomes e tipos das colunas.

Verificação da reprodução

Data da execução completa: 21/10/2026
Responsável: Leonardo Stall
Ambiente: Google Colab, utilizando Python 3 e PySpark.

As saídas salvas no notebook registram 584.010 linhas no conjunto limpo, com 41 colunas, e no conjunto transformado, com 45 colunas. A seção 6 registra a exportação para /content/ra1_acidentes_2025_transformados_parquet e a validação após a releitura, verificando a igualdade da quantidade de linhas e dos nomes e tipos das colunas em relação a df_transformado.

RA1 / 07

Referências e anexos

Reúna as fontes utilizadas e os materiais complementares que ajudam a verificar a entrega.

Referências

APACHE SOFTWARE FOUNDATION. PySpark: Python API for Apache Spark. Versão 4.0.4. Disponível em: https://spark.apache.org/docs/latest/api/python/. Acesso em: 21 out. 2026.

PYTHON SOFTWARE FOUNDATION. Python. Versão 3.13.16. Disponível em: https://www.python.org/. Acesso em: 21 out. 2026.

Ainda faltam dois campos, que só você consegue preencher:

- **LINK_DO_ARQUIVO:** o endereço da página onde você baixou o CSV de 2025 no portal da PRF. Se não tiver anotado, use o link da página de dados abertos: https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf.
- **DATA_CONSULTA_PRF:** a data em que você acessou o portal ou o dicionário. Se você lembra que foi em 09/10/2026, use essa data nas duas referências da PRF, como está na ficha da fonte.

GOOGLE. **Google Colaboratory**. Disponível em: https://colab.research.google.com/. Acesso em: 21 out. 2026.

POLÍCIA RODOVIÁRIA FEDERAL. **Acidentes de trânsito em rodovias federais agrupados por pessoa, 2025** [arquivo CSV]. Disponível em: <link exato do arquivo baixado>. Acesso em: 09 out. 2026.

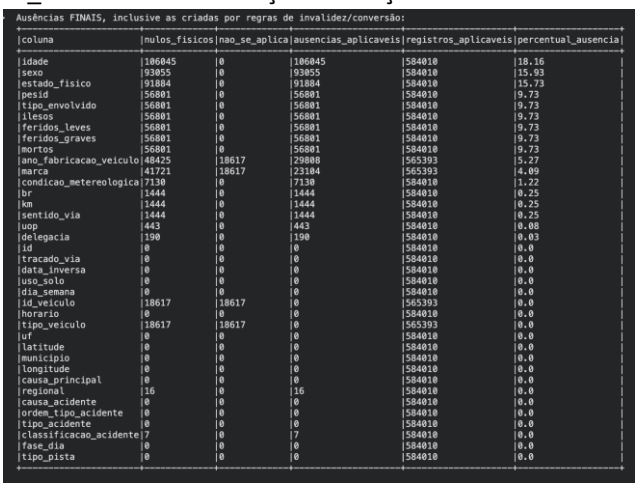
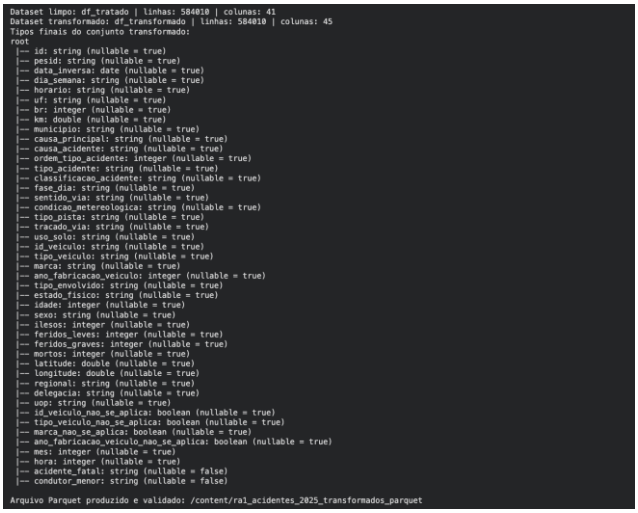
POLÍCIA RODOVIÁRIA FEDERAL. **Dicionário de dados de acidentes**. Disponível em: https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dicionario-acidentes. Acesso em: <data da consulta>.

Anexos opcionais

Identificação	Conteúdo	Localização
Anexo A	Dicionário completo dos 37 atributos originais, com tipo previsto e relação com as perguntas P1 a P5.	Projeto_Acidentes_2025_RA1_RA2.ipynb, seção 2.2

Dicionário dos 37 atributos e correspondência com as cinco perguntas:

atributo	tipo_previsto	significado	P1	P2	P3	P4	P5
id	string	Identificador do acidente	Sim	Sim	Sim	Sim	Sim
pesid	string	Identificador da pessoa	–	–	Sim	–	Sim
data_inversa	date	Data do acidente	Sim	Sim	–	–	–
dia_semana	string	Dia da semana	–	Sim	–	–	–
horario	string	Hora informada	–	Sim	–	–	–
uf	string	Unidade federativa	Sim	–	–	–	Sim
br	integer	Número da rodovia federal	Sim	–	–	–	–
km	double	Marco quilométrico	–	–	–	–	–
municipio	string	Município	–	–	–	–	–
causa_principal	string	Indicador da causa principal	–	–	–	–	–
causa_acidente	string	Causa registrada	–	–	–	–	–
ordem_tipo_acidente	integer	Ordem de registro do tipo de acidente	–	–	Sim	–	–
tipo_acidente	string	Tipo do acidente	–	–	Sim	–	–
classificacao_acidente	string	Classificação de gravidade do acidente	–	–	Sim	Sim	–
fase_dia	string	Condição de iluminação do período	–	–	–	Sim	–
sentido_via	string	Sentido de circulação	–	–	–	–	–
condicao_metereologica	string	Condição meteorológica	–	–	–	Sim	–
tipo_pista	string	Tipo de pista	–	–	–	–	–
tracado_via	string	Características do traçado	–	–	–	–	–
uso_solo	string	Uso do solo	–	–	–	–	–
id_veiculo	string	Identificador do veículo	–	–	–	–	Sim
tipo_veiculo	string	Categoria do veículo	–	–	–	–	Sim
marca	string	Marca do veículo	–	–	–	–	–
ano_fabricacao_veiculo	integer	Ano de fabricação	–	–	–	–	–
tipo_envolvido	string	Papel da pessoa envolvida	–	–	–	–	Sim
estado_fisico	string	Estado físico informado	–	–	–	–	–
idade	integer	Idade em anos	–	–	–	–	Sim
sexo	string	Sexo informado	–	–	–	–	–
ilesos	integer	Indicador individual de pessoa ilesa	–	–	–	–	–
feridos_leves	integer	Indicador individual de ferimento leve	–	–	–	–	–
feridos_graves	integer	Indicador individual de ferimento grave	–	–	–	–	–
mortos	integer	Indicador individual de morte	–	–	Sim	–	–
latitude	double	Coordenada geográfica	–	–	–	–	–
longitude	double	Coordenada geográfica	–	–	–	–	–
regional	string	Unidade regional PRF	–	–	–	–	–
delegacia	string	Delegacia PRF	–	–	–	–	–
uop	string	Unidade operacional PRF	–	–	–	–	–

Identificação	Conteúdo	Localização
Anexo B	Saída da execução da verificação de integridade do conjunto limpo: 584.010 linhas, 41 colunas em df_tratado e as verificações da seção 4.6. 	Projeto_Acidentes_2025_RA1_RA2.ipynb, seção 4.6
Anexo C	Saída da gravação e releitura do conjunto transformado: 45 colunas em df_transformado e mensagem “Arquivo Parquet produzido e validado”. 	Projeto_Acidentes_2025_RA1_RA2.ipynb, seção 6